HW_1

July 4, 2026

1 HW#2 — การวิเคราะห์ชุดข้อมูล Titanic (Data Quality Assessment & EDA)

รหัสนักศึกษา: 6710503739

เตรียมไลบรารีและโหลดข้อมูล

[20]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import missingno as msno
from scipy.stats import chi2_contingency, pearsonr

sns.set_theme(style="whitegrid")
plt.rcParams["figure.dpi"] = 100

df = pd.read_csv("titanic_data.csv")
df.columns = df.columns.str.strip()
print("ขนาดข้อมูล (แถว, คอลมัน์):", df.shape)
df.head()
```

```
ขนาดข้อมูล (แถว, คอลมัน์): (891, 12)
```

[20]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th…	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

```
1      0          PC 17599  71.2833   C85        C
2      0  STON/O2. 3101282   7.9250   NaN        S
3      0            113803  53.1000  C123        S
4      0            373450   8.0500   NaN        S
```

[2]:
```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
 #   Column       Non-Null Count  Dtype  
---  ------       --------------  -----  
 0   PassengerId  891 non-null    int64  
 1   Survived     891 non-null    int64  
 2   Pclass       891 non-null    int64  
 3   Name         891 non-null    str    
 4   Sex          891 non-null    str    
 5   Age          714 non-null    float64
 6   SibSp        891 non-null    int64  
 7   Parch        891 non-null    int64  
 8   Ticket       891 non-null    str    
 9   Fare         891 non-null    float64
 10  Cabin        204 non-null    str    
 11  Embarked     889 non-null    str    
dtypes: float64(2), int64(5), str(5)
memory usage: 83.7 KB
```

[21]:
```
df.describe(include='all')
```

[21]:

	PassengerId	Survived	Pclass	Name	Sex	\
count	891.000000	891.000000	891.000000	891	891	
unique	NaN	NaN	NaN	891	2	
top	NaN	NaN	NaN	Braund, Mr. Owen Harris	male	
freq	NaN	NaN	NaN	1	577	
mean	446.000000	0.383838	2.308642	NaN	NaN	
std	257.353842	0.486592	0.836071	NaN	NaN	
min	1.000000	0.000000	1.000000	NaN	NaN	
25%	223.500000	0.000000	2.000000	NaN	NaN	
50%	446.000000	0.000000	3.000000	NaN	NaN	
75%	668.500000	1.000000	3.000000	NaN	NaN	
max	891.000000	1.000000	3.000000	NaN	NaN	

	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
count	714.000000	891.000000	891.000000	891	891.000000	204	889
unique	NaN	NaN	NaN	681	NaN	147	3
top	NaN	NaN	NaN	347082	NaN	G6	S
freq	NaN	NaN	NaN	7	NaN	4	644
mean	29.699118	0.523008	0.381594	NaN	32.204208	NaN	NaN

std	14.526497	1.102743	0.806057	NaN	49.693429	NaN	NaN
min	0.420000	0.000000	0.000000	NaN	0.000000	NaN	NaN
25%	20.125000	0.000000	0.000000	NaN	7.910400	NaN	NaN
50%	28.000000	0.000000	0.000000	NaN	14.454200	NaN	NaN
75%	38.000000	1.000000	0.000000	NaN	31.000000	NaN	NaN
max	80.000000	8.000000	6.000000	NaN	512.329200	NaN	NaN

1.1 Question 2: Data Quality Assessment

1.1.1 Q2.1 การวิเคราะห์ข้อมูลสูญหาย (Missing Data Analysis)

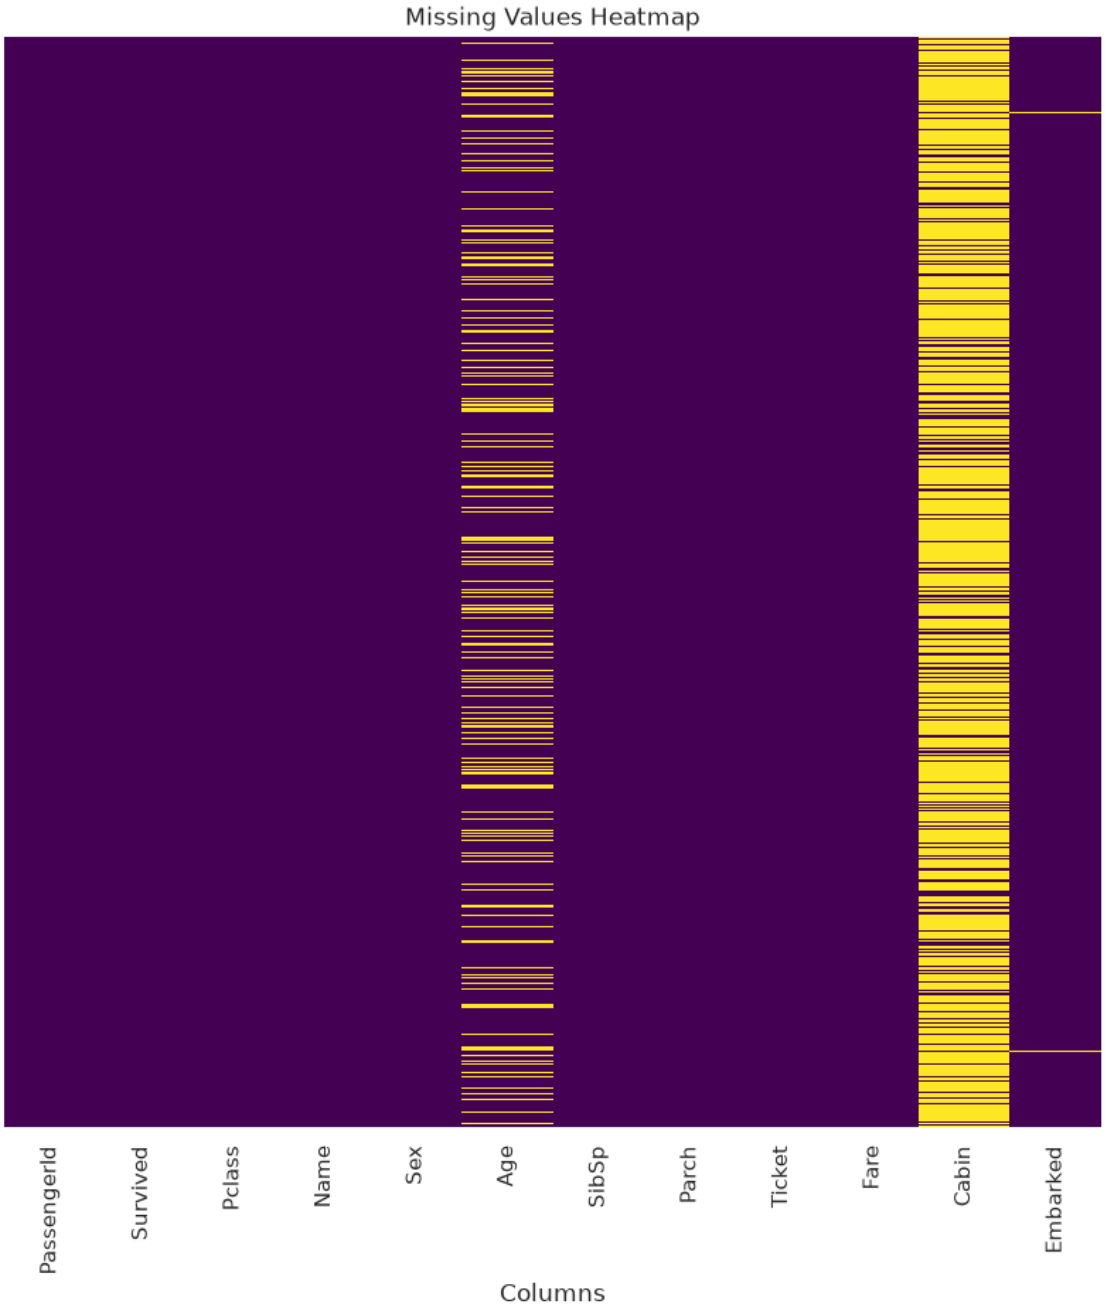
[22]:
```
missing = pd.DataFrame({
    'missing_count': df.isna().sum(),
    'missing_pct': (df.isna().mean() * 100).round(2)
})

missing
```

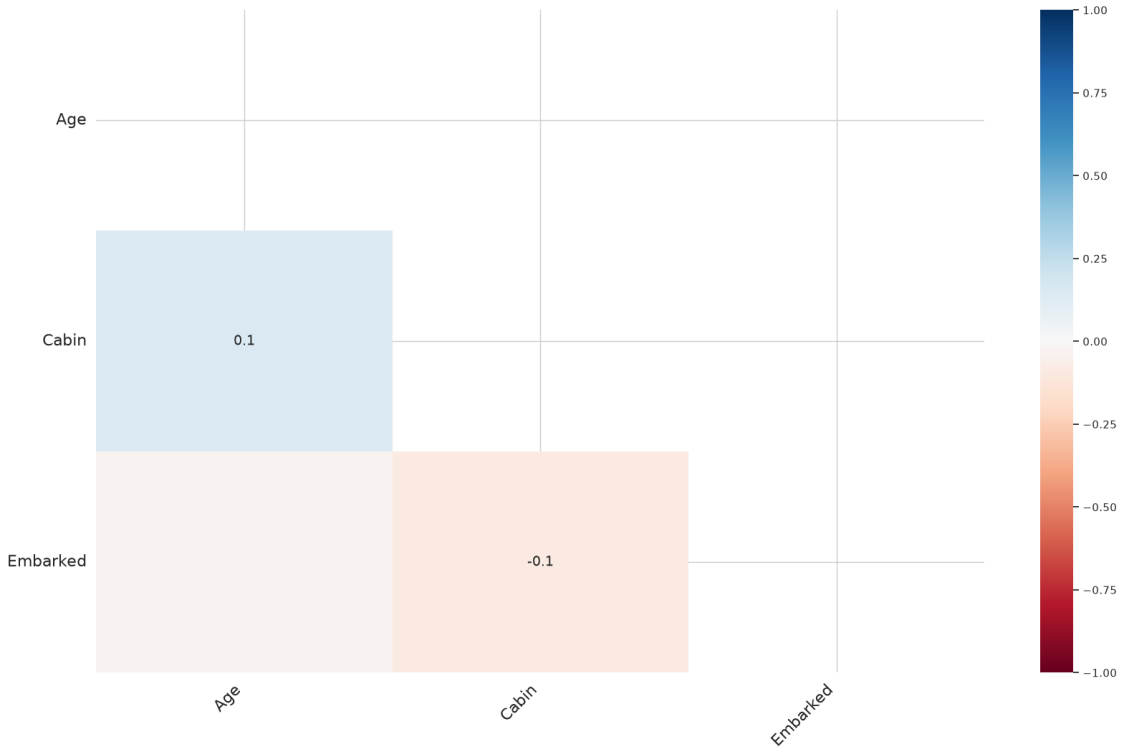
[22]:

	missing_count	missing_pct
PassengerId	0	0.00
Survived	0	0.00
Pclass	0	0.00
Name	0	0.00
Sex	0	0.00
Age	177	19.87
SibSp	0	0.00
Parch	0	0.00
Ticket	0	0.00
Fare	0	0.00
Cabin	687	77.10
Embarked	2	0.22

[24]:
```
plt.figure(figsize=(10, 10))
sns.heatmap(df.isna(), cbar=False, yticklabels=False, cmap='viridis')
plt.title('Missing Values Heatmap')
plt.xlabel('Columns')
plt.show()
```



[7]:
```
msno.heatmap(df)
plt.show()
```



สรุปผล Q2.1 คอลัมน์ที่มีค่าสูญหาย และเปอร์เซ็นต์: - Cabin - สูญหาย 77.10% มากที่สุด - Age - สูญหาย 19.87% - Embarked - สูญหาย 0.22% น้อยที่สุด

เหมาะสมหรือไม่ที่จะลบคอลัมน์ Cabin ทิ้งทั้งหมด? ตัวอักษรตัวแรกของ Cabin (C, E, B) บอก deck ซึ่งสัมพันธ์กับตำแหน่งบนเรือและโอกาสรอดชีวิต ควรสร้างข้อมูลใหม่ เช่น Deck แล้วค่อยลบคอลัมน์ดิบทิ้งเก็บข้อมูลที่มีประโยชน์ไว้

รูปแบบที่สังเกตได้จาก heatmap: - จาก nullity heatmap ค่าสหสัมพันธ์การหายระหว่างคอลัมน์อยู่ในระดับต่ำ นั่นคือ Age หาย ไม่ได้แปลว่า Cabin จะหายด้วย การหายของแต่ละคอลัมน์ค่อนข้างเป็นอิสระต่อกัน

1.1.2 Q2.2 การตรวจจับค่าผิดปกติ (Outlier Detection)

[8]:
```python
def iqr_outliers(series):
    s = series.dropna()
    q1, q3 = s.quantile(0.25), s.quantile(0.75)
    iqr = q3 - q1
    low, high = q1 - 1.5 * iqr, q3 + 1.5 * iqr
    mask = (s < low) | (s > high)
    return {
        'Q1': round(q1, 2), 'Q3': round(q3, 2), 'IQR': round(iqr, 2),
        'lower_bound': round(low, 2), 'upper_bound': round(high, 2),
        'n_outliers': int(mask.sum()),
```

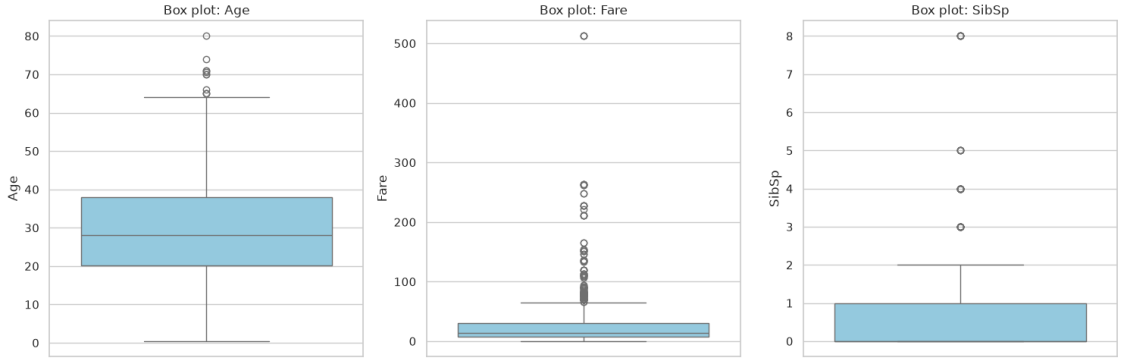
```
        'pct_outliers': round(mask.mean() * 100, 2),
    }

summary = pd.DataFrame({col: iqr_outliers(df[col]) for col in ['Age', 'Fare',
 ↪'SibSp']}).T
summary
```

[8]:

	Q1	Q3	IQR	lower_bound	upper_bound	n_outliers	pct_outliers
Age	20.12	38.0	17.88	-6.69	64.81	11.0	1.54
Fare	7.91	31.0	23.09	-26.72	65.63	116.0	13.02
SibSp	0.00	1.0	1.00	-1.50	2.50	46.0	5.16

[ ]:
```
fig, axes = plt.subplots(1, 3, figsize=(15, 5))
for ax, col in zip(axes, ['Age', 'Fare', 'SibSp']):
    sns.boxplot(y=df[col], ax=ax, color='skyblue')
    ax.set_title(f'Box plot: {col}')
plt.tight_layout()
plt.show()
```



สรุปผล Q2.2 outlier ที่ตรวจพบด้วย IQR: Age คือสูงเกิน 64.8 ปี, Fare สูงเกิน 65.6 สูงสุด 512.3, SibSp มากกว่า 2.5 คน

2) ทำไมเลือก IQR แทน Z-score? เพราะ Fare และ SibSp เบ้ขวาไม่ได้กระจายแบบปกติ Z-score ตั้งอยู่บนสมมติฐานการแจกแจงปกติและใช้ค่าเฉลี่ย/ส่วนเบี่ยงเบนมาตรฐาน

3) outlier ทั้งหมดเป็น “ข้อมูลเสีย” หรือไม่? ไม่ ส่วนใหญ่เป็นค่าจริงที่ถูกต้องเช่น ผู้โดยสารอายุ 80 ปี, ค่าโดยสาร 512.33 ปอนด์ของห้องสวีทชั้นหนึ่ง ล้วนเป็นค่าที่เกิดขึ้นได้จริง ไม่ใช่ความผิดพลาดในการบันทึก

4) ควรลบ outlier ของ Fare ก่อนสร้างโมเดลทำนายหรือไม่? ไม่ควรลบทิ้ง เพราะค่าโดยสารสูงสัมพันธ์โดยตรงกับชั้นโดยสารและฐานะ ซึ่งเป็น ตัวทำนายการรอดชีวิตได้ ทางเลือกที่ดีกว่าคือ แปลงค่า เพื่อลดอิทธิพลของค่าสุดโต่งโดยไม่ทิ้งข้อมูล

5) เทคนิคตรวจจับ outlier เพิ่มเติม (นอกจาก IQR):
Isolation Forest - ข้อดีคือทำงานกับหลายตัวแปรพร้อมกัน จับ outlier ที่เห็นได้เฉพาะ เมื่อพิจารณาหลายมิติ

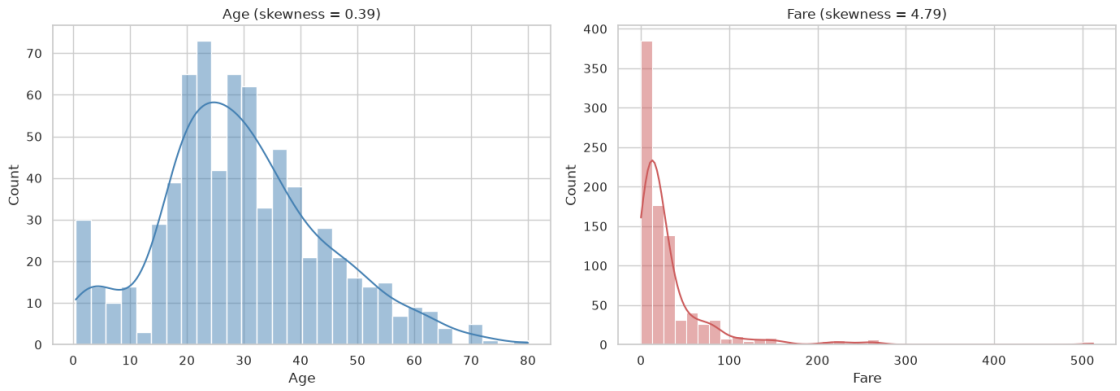
ไม่ต้องสมมติการแจกแจง และปรับขนาดกับข้อมูลใหญ่ได้ดี

6) ผลกระทบของ outlier ต่อการวิเคราะห์:
ดึงค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน mean ของ Fare 32 แต่ median เพียง 14.5 ทำให้ค่าสหสัมพันธ์และโมเดลเชิงเส้นไวต่อค่าเหล่านี้ จึงควรใช้ median, IQR และพิจารณาการแปลงค่าเสมอ

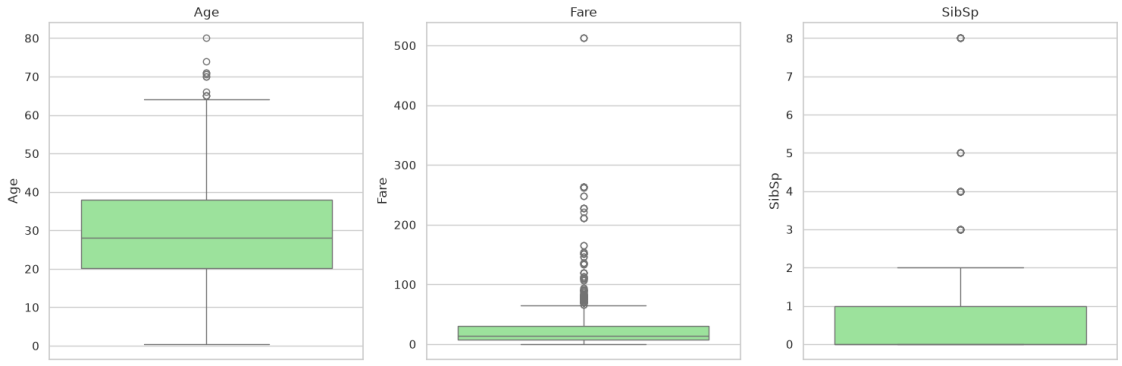
2 Question 3: Univariate Analysis

2.0.1 Q3.1 ตัวแปรเชิงตัวเลข (Numerical Variables)

[25]:
```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
sns.histplot(df['Age'].dropna(), bins=30, kde=True, ax=axes[0],
 ↪color='steelblue')
axes[0].set_title(f"Age (skewness = {df['Age'].skew():.2f})")
sns.histplot(df['Fare'].dropna(), bins=40, kde=True, ax=axes[1],
 ↪color='indianred')
axes[1].set_title(f"Fare (skewness = {df['Fare'].skew():.2f})")
plt.tight_layout()
plt.show()
```



[ ]:
```
fig, axes = plt.subplots(1, 3, figsize=(15, 5))
for ax, col in zip(axes, ['Age', 'Fare', 'SibSp']):
    sns.boxplot(y=df[col], ax=ax, color='lightgreen')
    ax.set_title(f'{col}')
plt.tight_layout()
plt.show()
```

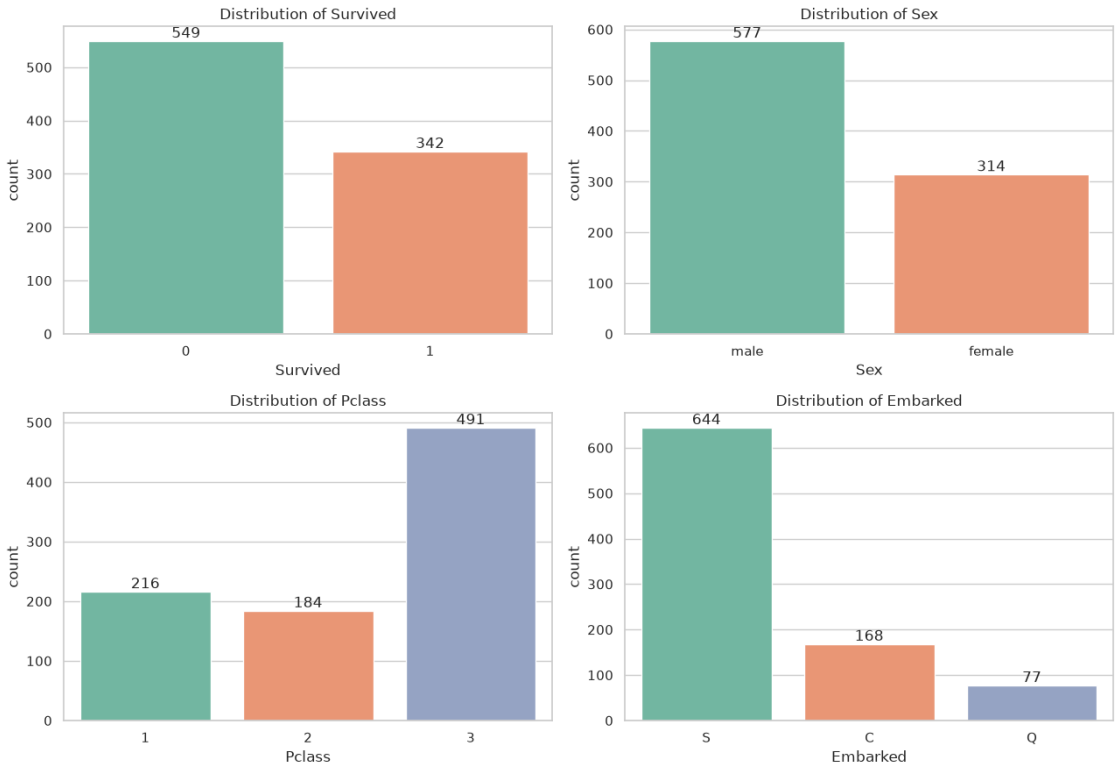


สรุปผล Q3.1 Histogram: - Age มีค่า skewness 0.39 - เบ้ขวาเล็กน้อย รูปทรงใกล้ระฆังคว่ำ กระจุกช่วง 20–40 ปี (mean 29.7 / median 28.0 ใกล้กัน) เกือบสมมาตร - Fare มีค่า skewness 4.79 — เบ้ขวาอย่างมาก ผู้โดยสารส่วนใหญ่จ่ายค่าโดยสารต่ำ (mean 32.2 / median 14.5)

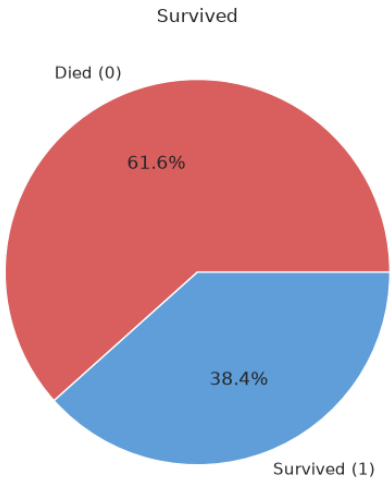
Box plot: - Age การกระจายสมมาตรที่สุด มี outlier ด้านสูงเพียงไม่กี่จุด - Fare กล่องถูกอัดที่ค่าต่ำ มี outlier ด้านสูงจำนวนมาก - SibSp mode = 0 ผู้โดยสารส่วนใหญ่เดินทางคนเดียว ค่าที่มากกว่า 3 กลายเป็น outlier - แนวโน้มสู่ศูนย์กลาง: median ของ Age สูงสุด (28), Fare (14.5), SibSp (0) ตามลำดับ

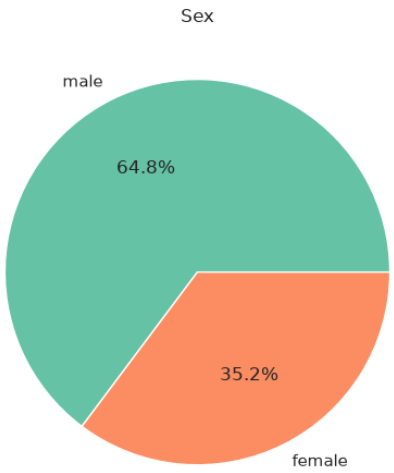
2.0.2 Q3.2 ตัวแปรเชิงหมวดหมู่ (Categorical Variables)

[ ]:
```
cat_cols = ['Survived', 'Sex', 'Pclass', 'Embarked']
fig, axes = plt.subplots(2, 2, figsize=(13, 9))
for ax, col in zip(axes.ravel(), cat_cols):
    sns.countplot(x=col, data=df, ax=ax, palette='Set2', hue=col, legend=False)
    ax.set_title(f'Distribution of {col}')
    for p in ax.patches:
        ax.annotate(int(p.get_height()), (p.get_x() + p.get_width()/2, p.
↪get_height()),
                    ha='center', va='bottom')
plt.tight_layout()
plt.show()
```



[ ]:
```
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
df['Survived'].value_counts().plot.pie(
    autopct='%1.1f%%', labels=['Died (0)', 'Survived (1)'],
    colors=['#d95f5f', '#5f9ed9'], ax=axes[0])
axes[0].set_title('Survived'); axes[0].set_ylabel('')
df['Sex'].value_counts().plot.pie(
    autopct='%1.1f%%', colors=['#66c2a5', '#fc8d62'], ax=axes[1])
axes[1].set_title('Sex'); axes[1].set_ylabel('')
plt.tight_layout()
plt.show()
```





สรุปผล Q3.2

- Survived: ผู้โดยสารรอดชีวิตเพียง 38.4% คนส่วนใหญ่เสียชีวิต - ข้อมูลไม่สมดุล (imbalanced)
- Sex: เพศชายมากกว่าเพศหญิงชัดเจน
- Pclass: ผู้โดยสารชั้น 3 มากที่สุด
- Embarked: ท่าเรือ S เป็นจุดขึ้นเรือหลัก รองลงมาคือ C และ Q
- ข้อสังเกต: ความไม่สมดุลของ Survived สำคัญต่อการเลือกเมตริกประเมินโมเดลภายหลัง

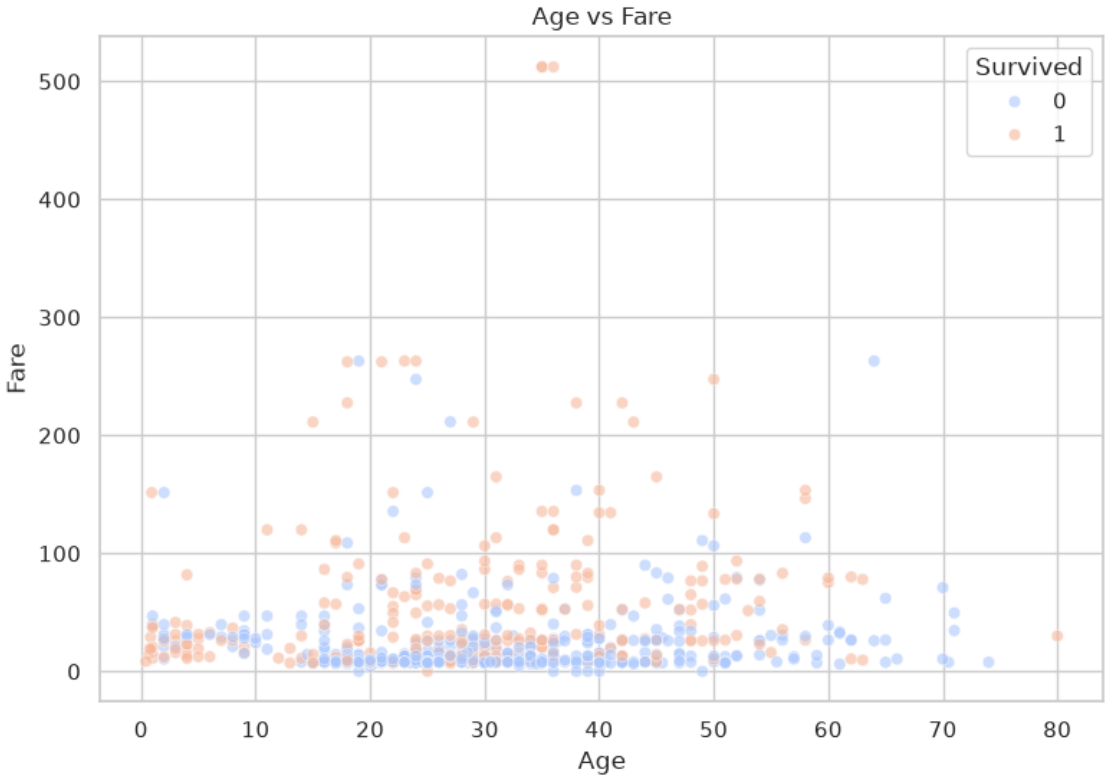
2.1 Question 4: Bivariate Analysis – Numerical Variables

2.1.1 Q4.1 การวิเคราะห์สหสัมพันธ์ (Correlation Analysis)

[26]:
```
sub = df[['Age', 'Fare']].dropna()
r, p_val = pearsonr(sub['Age'], sub['Fare'])
print(f'Pearson r = {r:.4f}')
print(f'p-value  = {p_val:.4g}')
```

```
Pearson r = 0.0961
p-value  = 0.01022
```

[ ]:
```
plt.figure(figsize=(9, 6))
sns.scatterplot(x='Age', y='Fare', hue='Survived', data=df, alpha=0.6,
 ↪palette='coolwarm')
plt.title('Age vs Fare')
plt.show()
```



สรุปผล Q4.1

- ค่า Pearson r 0.096 - เป็นความสัมพันธ์เชิงบวกที่อ่อนมาก แปลว่าอายุกับค่าโดยสารแทบไม่มีความสัมพันธ์เชิงเส้นต่อกัน
- Scatter plot: จุดกระจายกระจุกที่ค่าโดยสารต่ำในทุกช่วงอายุ ไม่เห็นแนวโน้มเชิงเส้นชัดเจน
- สังเกตกลุ่มค่าโดยสารสูงผิดปกติซึ่งส่วนใหญ่เป็นผู้รอดชีวิต - แปลว่าค่าโดยสารสัมพันธ์กับการรอดชีวิตมากกว่าที่อายุสัมพันธ์กับค่าโดยสาร

2.2 Question 5: Bivariate Analysis – Categorical Variables

2.2.1 Q5.1 ตารางความสัมพันธ์ (Contingency Table): Survived × Pclass

[27]:
```
ct = pd.crosstab(df['Pclass'], df['Survived'], margins=True)
ct.columns = ['Died(0)', 'Survived(1)', 'All']
print(ct)

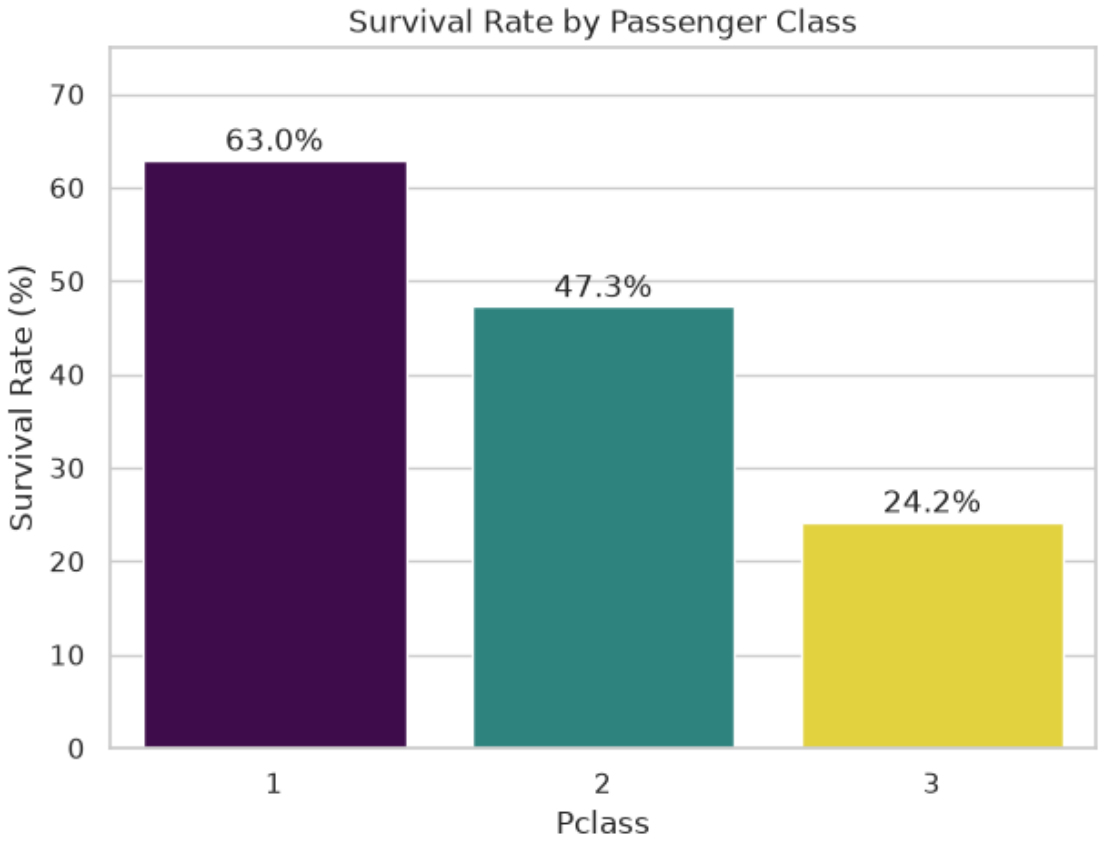
surv_pct = (df.groupby('Pclass')['Survived'].mean() * 100).round(2)
print('\nSurvival rate by Pclass (%):')
print(surv_pct)
```

```
        Died(0)  Survived(1)  All
Pclass
1            80          136  216
```

```
2             97           87  184
3            372          119  491
All          549          342  891

Survival rate by Pclass (%):
Pclass
1    62.96
2    47.28
3    24.24
Name: Survived, dtype: float64
```

[ ]:
```
plt.figure(figsize=(7, 5))
ax = sns.barplot(x=surv_pct.index, y=surv_pct.values, palette='viridis',
 ↪hue=surv_pct.index, legend=False)
for i, v in enumerate(surv_pct.values):
    ax.text(i, v + 1, f'{v:.1f}%', ha='center')
plt.title('Survival Rate by Passenger Class')
plt.ylabel('Survival Rate (%)'); plt.xlabel('Pclass')
plt.ylim(0, 75)
plt.show()
```



สรุปผล Q5.1 อัตราการรอดชีวิตลดลงชัดเจนตามชั้นโดยสารที่ต่ำลง - ผู้โดยสารชั้น 1 มีโอกาสรอดสูงกว่าชั้น 3 ชี้ว่าชั้นโดยสารสัมพันธ์อย่างมากกับการรอดชีวิต

2.2.2 Q5.2 การทดสอบทางสถิติ (Chi-Square Test of Independence)

[30]:
```
observed = pd.crosstab(df['Survived'], df['Pclass'])
chi2, p, dof, expected = chi2_contingency(observed)
print(f'Chi-square statistic = {chi2:.3f}')
print(f'p-value = {p:.3e}')
print(f'degrees of freedom = {dof}')
print('\nExpected frequencies:')
print(pd.DataFrame(expected, index=['Died', 'Survived'], columns=[1, 2, 3]).
 ↪round(1))
```

```
Chi-square statistic = 102.889
p-value = 4.549e-23
degrees of freedom = 2

Expected frequencies:
              1      2      3
Died      133.1  113.4  302.5
Survived   82.9   70.6  188.5
```

สรุปผล Q5.2 สมมติฐาน: - H0 : การรอดชีวิต และชั้นโดยสารเป็นอิสระต่อกัน - H1 : การรอดชีวิตและชั้นโดยสารมีความสัมพันธ์กัน

ผลการทดสอบ: power(x,2) = 102.89, p-value = 4.55 × power(10,-23), degrees of freedom = 2

ข้อสรุป: เนื่องจาก p-value น้อยกว่า 0.05 อย่างมาก จึงปฏิเสธ H0 สรุปได้ว่าการรอดชีวิตกับชั้นโดยสารมีความสัมพันธ์กันอย่างมีนัยสำคัญทางสถิติยืนยันข้อสังเกตจาก Q5.1 ว่าชั้นโดยสารเป็นปัจจัยสำคัญต่อการรอดชีวิต

2.3 Question 6: Multi-variate Analysis

2.3.1 Q6.1 Pairplot: Age, Fare, SibSp

[ ]:
```
pair_df = df[['Age', 'Fare', 'SibSp', 'Survived']].dropna()
sns.pairplot(pair_df, vars=['Age', 'Fare', 'SibSp'], hue='Survived',
             palette='coolwarm', diag_kind='kde', plot_kws={'alpha': 0.5})
plt.suptitle('Pairplot: Age, Fare, SibSp (by Survived)', y=1.02)
plt.show()
```



สรุปผล Q6.1

- ความสัมพันธ์ระหว่างตัวแปร: ทุกคู่ (Age-Fare, Age-SibSp, Fare-SibSp) แสดงความสัมพันธ์เชิงเส้นที่อ่อนมาก ไม่มีคู่ใดสัมพันธ์กันชัดเจน
- สัญญาณการรอดชีวิต: ในมิติ Fare ผู้ที่จ่ายค่าโดยสารสูงมีสัดส่วนรอดชีวิตมากกว่า - Fare ให้แยกแยะการรอดชีวิตได้ดีกว่า Age หรือ SibSp
- outlier ที่เห็นจาก pairplot: จุด Fare > 500, Age = 80 ปี, และ SibSp = 8 โดดออกจากกลุ่มหลักในทุกแกนที่เกี่ยวข้อง

2.3.2 สรุปภาพรวม

1. คุณภาพข้อมูล: ต้องจัดการค่าสูญหายใน Cabin (77%), Age (20%), Embarked (2 แถว) และมี extreme values ใน Fare,SibSp ที่เป็นค่าจริงควรแปลงค่ามากกว่าลบทิ้ง

2. ปัจจัยที่สัมพันธ์กับการรอดชีวิต: ชั้นโดยสาร และค่าโดยสารซึ่งสะท้อนฐานะมีความสัมพันธ์กับการรอดชีวิตอย่างมีนัยสำคัญขณะที่อายุมีบทบาทน้อยกว่า