In Class Exercise Imbalanced Classification

E0 No Sampling E1 Fixed Size Sampling E2 SMOTE

Scenario and objective

ทีม Customer Retention ต้องการค้นหาลูกค้าที่มีแนวโน้ม Churn แต่ข้อมูลมีจำนวน Churn = true น้อยกว่า false มาก งานนี้ให้นิสิตสร้าง baseline และเปรียบเทียบ sampling 2 วิธี โดยใช้ evaluation protocol เดียวกันทั้งหมด

- อธิบาย class imbalance และคำนวณ Imbalance Ratio
- เปรียบเทียบ E0 No Sampling, E1 Fixed Size Sampling และ E2 SMOTE
- ใช้ Stratified 5 fold Cross Validation โดย sampling เฉพาะ training data
- ตีความ Confusion Matrix, Precision, Recall และ F1 score ของ minority class

Important !!!

ห้ามทำ sampling ก่อน Cross Validation เพราะ test data อาจได้รับสำเนาหรือ synthetic records จาก training data ทำให้ผลประเมินสูงเกินจริง Sampling ต้องอยู่ใน Training subprocess เท่านั้น และ **test fold ต้องคง class distribution เดิม**

Part A EDA

1. ระบุ target attribute และกำหนด positive or minority class ให้ชัดเจน
2. แสดงจำนวน true และ false พร้อมคำนวณ IR = Nmajority / Nminority
3. ตรวจ missing values และอธิบายวิธีจัดการ
4. กำหนด Customer ID เป็น id role หรือตัดออกจาก predictors
5. ใช้ random seed = 1992 และ Stratified 5 fold Cross Validation

Part B Three controlled experiments

ใช้ Decision Tree และ parameters ชุดเดียวกันทุก experiment เพื่อให้ผลต่างเกิดจาก sampling เป็นหลัก

Experiment	Training strategy	Required setting
E0	No Sampling	Train ด้วยข้อมูลใน training fold เดิม
E1	Fixed Size Sampling	กำหนดจำนวนต่อ class เท่ากัน เช่น true = 300 และ false = 300
E2	SMOTE	k = 5, normalize = true, equalize classes, seed = 1992

E0 No Sampling baseline

- ไม่ปรับจำนวน class
- ใช้เป็น baseline เพื่อดูว่าโมเดลเอนเอียงไปทาง majority class หรือไม่

E1 Fixed Size Balanced Sampling

- วาง Sample operator ใน Training subprocess ของ Cross Validation
- ถ้ากำหนด true = 300 และ false = 300 โมเดลจะเรียนจาก 600 records ในแต่ละ CV iteration
- fixed size ต้องไม่เกินจำนวน minority records ที่อยู่ใน training portion ของแต่ละรอบ
- วิธีนี้ลด majority records จึงอาจสูญเสียข้อมูลสำคัญบางส่วน

E2 SMOTE

- วาง SMOTE Upsampling ใน Training subprocess เท่านั้น
- SMOTE สร้าง synthetic minority records ระหว่าง minority neighbors ไม่ใช่การ copy records เดิม
- เปิด normalize ภายใน SMOTE เพราะการหา neighbors อาศัยระยะทาง
- ทดสอบโมเดลกับ test fold เดิมที่ยัง imbalanced

Model and preprocessing requirements

- Customer ID ต้องเป็น id role หรือถูกตัดออก
- Decision Tree ไม่ต้อง scaling เพราะไม่ได้ใช้ระยะทาง
- E0–E2 ต้องใช้ Decision Tree parameters, folds และ random seed เดียวกัน
- แสดงค่าพารามิเตอร์สำคัญของ Decision Tree, Sample และ SMOTE

Part C Results

เติมค่าเฉลี่ยจาก 5 folds และแสดง Confusion Matrix ของทั้งสาม experiments

Experiment	Accuracy	Precision positive	Recall positive	F1 positive
E0 No Sampling				
E1 Fixed Size				
E2 SMOTE				

Part D Interpretation questions

6. เหตุใด Accuracy สูงจึงยังไม่เพียงพอสำหรับ imbalanced classification?
7. จาก E0 โมเดลพลาด minority class เป็น False Negative จำนวนเท่าใด?
8. E1 ทำให้ minority Recall เพิ่มขึ้นหรือไม่ และ Precision เปลี่ยนอย่างไร?
9. E2 แตกต่างจาก E1 อย่างไรในแง่ของการสร้าง training data?
10. วิธีใดลด False Negative ได้มากที่สุด และต้องแลกกับ False Positive เพิ่มขึ้นเท่าใด?
11. เลือก final model หนึ่งวิธี พร้อมอธิบายจาก Recall, Precision, F1 และ Confusion Matrix ห้ามเลือกจาก Accuracy เพียงค่าเดียว

Submission

- StudentID_Imbalanced_InClass.xml หรือ StudentID_Imbalanced_InClass.ipynb
- StudentID_Imbalanced_InClass_Report.pdf